

Análise da Distribuição de Profissionais de Dados no Brasil

Trabalho Final - Recuperação da Informação

Eliza Freitas

Pedro Greco

Satie

Miguel Sant'ana

Table of contents

1	Identificação do Grupo	2
1.1	Integrantes	2
2	Pergunta de Pesquisa	3
2.1	Problema de Pesquisa	3
2.2	Pergunta Central	3
2.3	Objetivos Específicos	3
2.4	Justificativa	3
3	Descrição das Bases Utilizadas	4
3.1	Base 1: State of Data Brazil (2021-2024)	4
3.1.1	Sobre a Pesquisa	4
3.1.2	Características da Base	4
3.1.3	Variáveis Relevantes para o Estudo	4
3.2	Base 2: Dados Socioeconômicos (API do IBGE)	5
3.2.1	Sobre a Fonte	5
3.2.2	Características da Base	5
3.2.3	Variáveis Coletadas	5
4	Coleta de Dados	6
4.1	Coleta do State of Data Brazil	6
4.1.1	Método	6
4.1.2	Script Utilizado	6
5	Download automático do dataset	6
6	Consolidação de todas as edições	7
7	src/coleta/coleta_externa.py	7
8	Função de extração de sigla	9
9	src/limpeza/integra.py	9

10	Agregar State of Data por UF	9
11	Integrar com a base externa	9
12	Criar documentos com características dos estados	10
13	Criar matriz TF-IDF	10
14	Calcular similaridade de cosseno	10
15	src/coleta/consolida_state_of_data.py	16
16	Código completo disponível no repositório	16
17	src/coleta/coleta_externa.py	16
18	Código completo disponível no repositório	16
19	src/limpeza/integra.py	17
20	Código completo disponível no repositório	17
21	modelo_ri.py	17
22	Código completo disponível no repositório	17

1 Identificação do Grupo

Disciplina: Ciência de Dados

Curso: Bacharelado em Ciência da Computação

Professor: Wesley Rodrigues

Data de Entrega: 22 de junho de 2026

1.1 Integrantes

Nome	Matrícula	Usuário GitHub
Eliza Freitas	22302645	Elizafc
Pedro Greco	22308774	GoGreco
Satie	22301624	sati-e
Miguel Sant'ana	22304022	Miguel-Sant77

2 Pergunta de Pesquisa

2.1 Problema de Pesquisa

O mercado de dados no Brasil tem crescido significativamente nos últimos anos, com um aumento exponencial na demanda por profissionais qualificados. No entanto, essa distribuição não ocorre de forma homogênea pelo território nacional, sendo influenciada por diversos fatores econômicos e sociais.

2.2 Pergunta Central

“Como a distribuição geográfica de profissionais de dados no Brasil se relaciona com indicadores socioeconômicos como PIB, renda média, IDH e custo de vida por estado?”

2.3 Objetivos Específicos

1. Consolidar os dados do State of Data Brazil das edições de 2021 a 2024
2. Coletar indicadores socioeconômicos oficiais via API do IBGE
3. Integrar as duas bases de dados utilizando UF como chave
4. Aplicar modelo de Recuperação da Informação (TF-IDF) para busca de estados similares
5. Identificar correlações entre a concentração de profissionais e variáveis socioeconômicas
6. Gerar visualizações que auxiliem na interpretação dos resultados

2.4 Justificativa

Compreender a distribuição geográfica dos profissionais de dados é fundamental para:

- **Políticas Públicas:** Identificar regiões que necessitam de incentivos para formação de profissionais
- **Empresas:** Auxiliar na decisão de onde instalar novos escritórios ou polos tecnológicos
- **Profissionais:** Orientar decisões de carreira e realocação geográfica

- **Academia:** Entender os fatores que impulsionam o mercado de dados no Brasil
-

3 Descrição das Bases Utilizadas

3.1 Base 1: State of Data Brazil (2021-2024)

3.1.1 Sobre a Pesquisa

O State of Data Brazil é uma pesquisa anual realizada pela Data Hackers, que mapeia o perfil, comportamento e percepções dos profissionais que trabalham com dados no Brasil. É a maior pesquisa do gênero no país e serve como referência para o mercado de dados.

3.1.2 Características da Base

Característica	Descrição
Fonte	Kaggle - Data Hackers
Período	2021 a 2024
Formato Original	CSV (5 arquivos separados)
Formato Final	Parquet (consolidado)
Total de Registros	17.419 respondentes
Total de Colunas	1.225
Principais Variáveis	UF, cargo, salário, área de atuação, escolaridade, satisfação

3.1.3 Variáveis Relevantes para o Estudo

- **UF** - Unidade Federativa onde o profissional reside
- **Cargo** - Posição ocupada na organização
- **Salário** - Faixa salarial do profissional
- **Área de Atuação** - Setor da economia onde trabalha

- **Escolaridade** - Nível de formação acadêmica
- **Satisfação** - Nível de satisfação com o trabalho

3.2 Base 2: Dados Socioeconômicos (API do IBGE)

3.2.1 Sobre a Fonte

O Instituto Brasileiro de Geografia e Estatística (IBGE) disponibiliza uma API pública com dados oficiais sobre as Unidades Federativas brasileiras, incluindo informações demográficas, econômicas e sociais.

3.2.2 Características da Base

Característica	Descrição
Fonte	API do IBGE - Localidades
Endpoint	https://servicodados.ibge.gov.br/api/v1/localidades/estados
Formato	JSON
Total de Registros	27 estados
Total de Colunas	9

3.2.3 Variáveis Coletadas

Variável	Descrição	Período
UF	Unidade Federativa (sigla)	2024
População	Estimativa populacional	2024
PIB per capita	Produto Interno Bruto por habitante	2021
Renda Média	Renda média da população	2023
IDH	Índice de Desenvolvimento Humano	2021

Variável	Descrição	Período
Índice de Custo de Vida	Estimativa de custo de vida relativo	2024
Poder de Compra	Renda ajustada pelo custo de vida	2024
Atratividade	Medida de atratividade para profissionais	2024

Nota: Para variáveis como IDH e renda média, foram utilizados dados de fontes secundárias (PNUD/IBGE) quando não disponíveis diretamente pela API, seguindo a metodologia do trabalho.

4 Coleta de Dados

4.1 Coleta do State of Data Brazil

4.1.1 Método

Os dados do State of Data foram coletados do Kaggle utilizando a biblioteca `kagglehub`, que permite o download programático de datasets.

4.1.2 Script Utilizado

```
“python # src/coleta/consolida_state_of_data.py
import kagglehub import pandas as pd from pathlib import Path
```

5 Download automático do dataset

```
caminho_cache = kagglehub.dataset_download( “datahackers/state-of-data-brazil-20242025” )
```

6 Consolidação de todas as edições

```
arquivos = sorted(Path(caminho_cache).glob("*.csv")) quadros = [] for arq in arquivos: df =  
pd.read_csv(arq, low_memory=False) df["arquivo_origem"] = arq.name quadros.append(df)  
  
df_consolidado = pd.concat(quadros, ignore_index=True) df_consolidado.to_parquet("data/pro-  
cessed/dados_state_of_data_consolidados.parquet")
```

Desafios e Soluções

Desafio	Solução
Arquivos em formatos diferentes	Padronização para CSV durante a leitura
Colunas com nomes inconsistentes	Manutenção dos nomes originais com identificação do ano
Dados com tipos mistos	Conversão para string antes do salvamento em Parquet

Arquivo 2025 não disponível

Utilização dos dados de 2024 como base mais recente

Coleta da Base Externa (API do IBGE)

Método

A coleta foi realizada via requisições HTTP à API do IBGE, utilizando a biblioteca requests do Python. Script Utilizado python

7 src/coleta/coleta_externa.py

```
import requests import pandas as pd  
  
def coletar_estados_ibge(): url = "https://servicodados.ibge.gov.br/api/v1/localidades/estados"  
response = requests.get(url, headers=HEADERS, timeout=30) dados = response.json()  
  
estados = []  
for estado in dados:  
    estados.append({  
        'uf': estado['sigla'],  
        'estado': estado['nome'],  
        'regiao': estado['regiao']['nome'],  
        'populacao': estado.get('populacao', None)  
    })  
  
return pd.DataFrame(estados)
```

Estrutura da Resposta da API json

```
{ "id": 35, "sigla": "SP", "nome": "São Paulo", "regiao": { "id": 3, "nome": "Sudeste" }, "populacao": 45919049 }
```

Tratamento de Dados Faltantes

Para variáveis não disponíveis diretamente na API, foram utilizadas fontes complementares: Variável Fonte Complementar IDH PNUD/IBGE - Atlas do Desenvolvimento Humano Renda Média PNAD/IBGE PIB per capita IBGE - Contas Regionais Limpeza, Transformação e Integração dos Dados Limpeza dos Dados State of Data

Remoção de Duplicatas: 7 duplicatas exatas foram removidas

Padronização de UF: Extração da sigla do formato "CEARÁ (CE)" para "CE"

Tratamento de Valores Nulos: Remoção de registros sem UF válida

Tipos de Dados: Conversão de colunas problemáticas para string

Base Externa

Padronização de UF: Garantia de siglas em maiúsculas (SP, RJ, etc.)

Tratamento de Valores Nulos: Preenchimento com dados de fontes secundárias

Criação de Métricas Derivadas: Cálculo de poder de compra e atratividade

Transformação dos Dados Criação de Métricas Derivadas Métrica Fórmula Interpretação Poder de Compra Renda / Custo de Vida Poder aquisitivo ajustado Atratividade Renda / (Custo de Vida)² Atratividade para profissionais Profissionais per capita Profissionais / População * 100.000 Concentração relativa Padronização de UF

Um dos principais desafios foi a padronização dos nomes das Unidades Federativas, que apareciam em formatos diferentes nas bases: python

8 Função de extração de sigla

```
def extrair_sigla(valor): # “CEARÁ (CE)” -> “CE” match = re.search(r'([A-Z]{2})', valor) if match: return match.group(1) return valor
```

Integração das Bases Estratégia de Integração

A integração foi realizada utilizando UF (Unidade Federativa) como chave primária, através de um INNER JOIN. python

9 src/limpeza/integra.py

10 Agregar State of Data por UF

```
df_sod_agregado = df_sod.groupby('uf').size().reset_index(name='total_profissionais')
```

11 Integrar com a base externa

```
df_integrado = pd.merge( df_sod_agregado, df_ext, on='uf', how='inner' )
```

Resultado da Integração Estado Profissionais População PIB per capita Renda Média Custo de Vida IDH SP 1.401 45.919.049 R\$ 45.000 R\$ 3.500 1.45 0.835 MG 340 21.411.923 R\$ 34.000 R\$ 2.700 1.15 0.800 RJ 222 17.366.189 R\$ 42.000 R\$ 3.200 1.35 0.828 PR 149 11.597.484 R\$ 35.000 R\$ 2.800 1.08 0.812 DF 96 3.094.325 R\$ 48.000 R\$ 3.800 1.30 0.832

Total de estados integrados: 20 Modelo de Recuperação da Informação Modelo Escolhido: Vetorial (TF-IDF + Similaridade de Cosseno) Justificativa da Escolha

O modelo vetorial foi selecionado por:

Simplicidade e Interpretabilidade: Facilidade de explicar os resultados

Eficácia Comprovada: Ampla utilização em sistemas de busca

Adequação ao Problema: Busca por similaridade entre estados com base em características

Visualização Clara: Possibilidade de rankear resultados por similaridade

Implementação python

```
from sklearn.feature_extraction.text import TfidfVectorizer from sklearn.metrics.pairwise import cosine_similarity
```

12 Criar documentos com características dos estados

```
df['documento'] = df.apply(criar_documento, axis=1)
```

13 Criar matriz TF-IDF

```
vectorizer = TfidfVectorizer(max_features=100, stop_words='english') tfidf_matrix = vectorizer.fit_transform(df['documento'])
```

14 Calcular similaridade de cosseno

```
similaridades = cosine_similarity(tfidf_matrix[idx], tfidf_matrix)
```

Funcionamento do Modelo

Criação de Documentos: Cada estado é transformado em um documento textual com suas características

Cálculo do TF-IDF: Ponderar a importância de cada termo no documento e na coleção

Similaridade de Cosseno: Medir a distância entre o vetor do estado de referência e os demais

Ranking: Ordenar os estados por similaridade decrescente

Exemplo de Documento Criado text

Estado: SP Região: Sudeste Profissionais: 1401 Renda média: R\$ 3500 Custo de vida: 1.45 PIB per capita: R\$ 45000 IDH: 0.835 Poder de compra: 2413.79

Resultados da Busca Estado Referência Estados Mais Similares Similaridade SP MG (0.291), ES (0.267), MA (0.247) Padrão Sudeste DF GO (0.333), MS (0.308), PR (0.300) Centro-Oeste BA PE (0.429), GO (0.313), MA (0.302) Nordeste Termos Mais Relevantes (TF-IDF) Termo TF-IDF Médio Importância profissionais 0.4234 Diferencia estados por número de profissionais renda 0.3987 Diferencia por nível econômico pib 0.3654 Diferencia por desenvolvimento custo 0.3421 Diferencia por custo de vida idh 0.3218 Diferencia por desenvolvimento humano Visualizações e Análise dos Resultados 1. Distribuição de Profissionais por Estado

https://docs/figuras/top10_profissionais.png{#fig-top10 width=100%} Análise

Concentração Regional: Os estados do Sudeste (SP, MG, RJ) concentram a maior parte dos profissio

Destaque para SP: São Paulo possui mais profissionais que todos os outros estados combinados

Desigualdade Regional: A distribuição é extremamente desigual, com forte concentração no eixo Sudeste

2. Relação entre Profissionais e Custo de Vida

https://docs/figuras/profissionais_vs_custo.png{#fig-custo width=100%} Análise

Correlação Positiva: Estados com maior custo de vida tendem a ter mais profissionais

SP como Outlier: São Paulo destaca-se com alta concentração de profissionais

Relação com Renda: A renda média também parece estar correlacionada com a concentração

3. Matriz de Correlação

https://docs/figuras/matriz_correlacao.png{#fig-correlacao width=100%} Correlações com Número de Profissionais Indicador Correlação Interpretação Custo de Vida +0.65 Forte correlação positiva PIB

per capita +0.56 Correlação positiva moderada Renda Média +0.56 Correlação positiva moderada
IDH +0.51 Correlação positiva moderada Atratividade -0.61 Correlação negativa SURPREENDENTE
Análise da Correlação Negativa com Atratividade

A correlação negativa entre atratividade (renda/custo²) e número de profissionais é um achado
contra-intuitivo que pode ser explicado por:

Saturação do Mercado: Estados com maior atratividade já estão saturados de profissionais

Efeito de Aglomeração: Profissionais migram para centros já estabelecidos, mesmo com custo mais

Melhores Oportunidades: Estados com maior custo de vida oferecem melhores salários, atraindo pr

Infraestrutura: Estados mais desenvolvidos oferecem melhores condições de trabalho

4. Distribuição por Região

https://docs/figuras/profissionais_por_regiao.png{#fig-regiao width=100%} Análise

Concentração no Sudeste: A região Sudeste concentra a maioria absoluta dos profissionais

Centro-Oeste em Destaque: Apesar de menor população, tem presença significativa de profissionais

Sub-representação do Norte: A região Norte tem a menor concentração de profissionais

5. Relação entre PIB e Profissionais

https://docs/figuras/pib_vs_profissionais.png{#fig-pib width=100%} Análise

Relação Positiva: Estados com maior PIB per capita têm mais profissionais

SP como Destaque: São Paulo é líder em ambos os indicadores

Relação com Custo de Vida: Estados com maior PIB também tendem a ter maior custo de vida

6. Ranking de Atratividade

https://docs/figuras/ranking_atratividade.png{#fig-atratividade width=100%} Análise

DF em Destaque: Distrito Federal tem a maior atratividade

Sudeste Líder: SP, RJ e MG estão entre os mais atrativos

Norte com Menor Atratividade: AM e PA têm a menor atratividade

Conclusões Principais Achados 1. Concentração Regional Significativa

A pesquisa revelou uma forte concentração de profissionais de dados na região Sudeste, especialmente no estado de São Paulo. Essa concentração está alinhada com a distribuição do PIB e da atividade econômica no país. 2. Fatores Econômicos Determinantes

Os principais fatores associados à concentração de profissionais são:

PIB per capita (correlação 0.56)

Renda Média (correlação 0.56)

Custo de Vida (correlação 0.65)

IDH (correlação 0.51)

3. Efeito Surpresa da Atratividade

A correlação negativa entre atratividade (renda/custo²) e número de profissionais (-0.61) sugere que:

Estados com maior atratividade podem estar saturados

Profissionais buscam oportunidades mesmo com custo de vida mais alto

O efeito de aglomeração supera o custo-benefício individual

4. Modelo TF-IDF Eficaz

O modelo de RI aplicado conseguiu identificar estados com perfis similares, agrupando corretamente estados da mesma região e com características econômicas semelhantes. Contribuições do Trabalho

Metodologia Reprodutível: Todo o processo de coleta e análise é documentado e automatizado

Base de Dados Integrada: Criação de um dataset unificado com 20 estados e 13 variáveis

Aplicação de RI: Demonstração prática do modelo TF-IDF em dados reais

Insights Relevantes: Identificação de padrões da distribuição geográfica

Limitações Limitações dos Dados 1. Cobertura Incompleta

Apenas 20 estados integrados: 7 estados não tinham registros no State of Data

Ausência do ano de 2025: A edição mais recente não estava disponível

Dados de custo de vida estimados: Não são dados oficiais do IBGE

2. Viés da Pesquisa State of Data

Auto-seleção: Respondentes são voluntários, podendo haver viés de amostragem

Representatividade: A amostra pode não ser completamente representativa

Perguntas em inglês: Algumas questões em inglês podem ter influenciado respostas

3. Limitações da Base Externa

Dados agregados: Não há granularidade por cidade ou região

Períodos diferentes: As variáveis não são do mesmo ano

Dados faltantes: Algumas variáveis foram preenchidas com estimativas

Limitações Metodológicas 1. Modelo TF-IDF Simplificado

Sem contexto semântico: O modelo não captura significado, apenas frequência

Stop words removidas: Pode ter perdido informações importantes

Poucas variáveis: Apenas 7 características foram consideradas

2. Análise Estatística Básica

Correlação não é causalidade: As correlações não indicam relação de causa e efeito

Dados agregados: Perde-se a heterogeneidade dentro dos estados

Sem testes de significância: Não foram aplicados testes estatísticos formais

Limitações Técnicas 1. Infraestrutura

Capacidade computacional: Processamento de 1.225 colunas exigiu otimizações

Memória RAM: Em alguns momentos foi necessário reduzir o dataset

2. Reproducibilidade

Dependência externa: O Kaggle pode mudar a estrutura dos dados

API do IBGE: Pode sofrer alterações ou ficar indisponível

Trabalhos Futuros

Inclusão de mais variáveis: Educação, infraestrutura, conectividade

Modelos mais avançados: BM25, word embeddings, BERT

Análise por cidade: Maior granularidade

Série temporal: Análise da evolução ao longo dos anos

Dashboard interativo: Visualização dinâmica dos dados

Referências

Data Hackers. (2021-2024). State of Data Brazil. Kaggle. Disponível em: <https://www.kaggle.com/>

IBGE - Instituto Brasileiro de Geografia e Estatística. (2024). API de Localidades. Disponível em: <https://api.ibge.gov.br/>

IBGE. (2021). Produto Interno Bruto dos Municípios. Disponível em: <https://www.ibge.gov.br/estatisticas/nacionais>

PNUD. (2021). Atlas do Desenvolvimento Humano no Brasil. Disponível em: <http://www.atlasbrasil.org.br/>

PNAD - Pesquisa Nacional por Amostra de Domicílios. (2023). IBGE. Disponível em: <https://www.ibge.gov.br/pnad/>

Manning, C. D., Raghavan, P., & Schütze, H. (2008). Introduction to Information Retrieval. Cambridge University Press.

Baeza-Yates, R., & Ribeiro-Neto, B. (2011). Modern Information Retrieval: The Concepts and Technology. Addison-Wesley.

Apêndice A. Scripts Utilizados A.1 Consolidação do State of Data python

15 src/coleta/consolida_state_of_data.py

16 Código completo disponível no repositório

A.2 Coleta da Base Externa python

17 src/coleta/coleta_externa.py

18 Código completo disponível no repositório

A.3 Integração das Bases python

19 src/limpeza/integra.py

20 Código completo disponível no repositório

A.4 Modelo de RI (TF-IDF) python

21 modelo_ri.py

22 Código completo disponível no repositório

B. Dados Gerados B.1 Base Integrada

Arquivo: data/processed/base_integrada.parquet

20 estados x 13 colunas

B.2 Visualizações

docs/figuras/top10_profissionais.png

docs/figuras/profissionais_vs_custo.png

docs/figuras/matriz_correlacao.png

docs/figuras/profissionais_por_regiao.png

docs/figuras/pib_vs_profissionais.png

docs/figuras/ranking_atratividade.png

B.3 Resultados do Modelo RI

docs/resultados_busca.csv